Relatório técnico — modelo preditivo de pico de risco

Projeto CardioIA | Classificação supervisionada em base clínica e operacional sintética

1. Objetivo e recorte experimental

Desenvolver um classificador binário para identificar possíveis picos de risco em cenários simulados, com posterior integração a um sistema multiagente. O exercício avalia um pipeline de dados, treinamento, validação e consulta ao modelo. Não utiliza prontuários nem comprova capacidade de previsão clínica.

2. Conjunto de dados e definição da variável-alvo

Foram gerados 5.000 registros sintéticos com semente aleatória 42, conforme o enunciado. Cada registro contém dez variáveis: idade média, carga do sistema, tempo de espera, frequência cardíaca média, SpO_2 média, pressão arterial sistólica, temperatura, densidade de eventos, eventos nas últimas 24 horas e disponibilidade de recursos. A variável **pico_risco** é 1 quando pelo menos duas entre seis condições são atendidas: carga > 80, espera > 60, SpO_2 < 92, frequência cardíaca > 110, eventos_24h > 4 e disponibilidade < 40. Caso contrário, recebe 0.

3. Preparação dos dados e treinamento

O código verifica ausência de valores nulos nas colunas utilizadas, mantém a ordem das dez variáveis e divide a base em 80% para treinamento e 20% para teste, com estratificação por classe (*train_test_split*, random_state=42). Utilizou-se **RandomForestClassifier**, com 100 árvores, profundidade máxima 10, mínimo de 5 amostras por divisão e random_state=42. O algoritmo foi escolhido pela capacidade de representar combinações não lineares de limiares, pela robustez em dados tabulares e por disponibilizar predição de classe e estimativa de probabilidade.

4. Resultados da avaliação

Indicador	Resultado	Indicador	Resultado
Registros (treino)	4.000	Registros (teste)	1.000
Acurácia	99,90%	Precisão (classe 1)	100,00%
Recall (classe 1)	99,62%	F1-score (classe 1)	99,81%
ROC-AUC	1,0000	Semente	42

Matriz de confusão (linhas: classe real; colunas: classe prevista)

	Previsto 0	Previsto 1
Real 0	734	0
Real 1	1	265

Análise dos resultados e integração

5. Interpretação da matriz de confusão

No conjunto de teste foram observados 734 verdadeiros negativos, 265 verdadeiros positivos, nenhum falso positivo e um falso negativo. A acurácia de 99,90% significa 999 classificações corretas em 1.000 casos. A precisão de 100% indica que não houve falsos positivos nessa amostra; o recall de 99,62% indica que um registro efetivamente rotulado como pico de risco não foi identificado pelo classificador. O F1-score sintetiza o equilíbrio entre precisão e recall.

6. Integração com o sistema multiagente

O classificador é serializado com *joblib* no arquivo agents/modelo_risco_cardiaco.pkl. Na execução do caso simulado, o Agente Analista de Risco consulta esse arquivo por uma ferramenta do OpenAI Agents SDK; as próximas etapas avaliam as condições de dez protocolos simulados e organizam a resposta. No cenário de teste, o modelo retornou probabilidade 1,0000 e classe 1 (pico de risco). Quatro regras foram ativadas: carga do sistema > 85%, disponibilidade de recursos < 30%, densidade de eventos > 6 e risco sistêmico alto.

7. Limitações do experimento

A variável-alvo foi definida por regras sobre as próprias variáveis de entrada. Por isso, o modelo aprende a reproduzir uma rotulagem determinística e tende a apresentar métricas elevadas; isso não constitui evidência de acurácia em eventos cardíacos reais. Os dados não descrevem a diversidade de pacientes ou hospitais, não contemplam desfechos verificados e não representam séries temporais clínicas acompanhadas ao longo do tempo.

A probabilidade **1,0000** expressa a estimativa do classificador para um caso sintético. Não deve ser interpretada como probabilidade clínica calibrada. Além disso, regras operacionais e limiares do enunciado são didáticos, não diretrizes assistenciais validadas.

8. Possíveis melhorias

Em uma etapa futura, seria necessário trabalhar com dados reais coletados sob consentimento e governança adequados, revisar a definição dos rótulos com profissionais de saúde, verificar desequilíbrios de classe, realizar validação externa e temporal, avaliar calibração de probabilidades e inspecionar o custo relativo de falsos positivos e falsos negativos. Na aplicação, recomenda-se testar novos cenários, registrar versões do modelo e manter monitoramento de desvio dos dados.

9. Conclusão

A implementação atendeu ao objetivo acadêmico de gerar dados, treinar e validar um modelo supervisionado, salvá-lo e utilizá-lo em um fluxo com agentes especializados. Os resultados sustentam o funcionamento técnico da solução sobre a base proposta, preservada a distinção entre demonstração computacional e utilização em saúde real.